Universidad de los Andes | Facultad de Ingeniería

Aprendizaje por Refuerzo

Nicolás Cardozo, Profesor Asociado
Departamento de Ingeniería de Sistemas y Computación
@FLAGlab

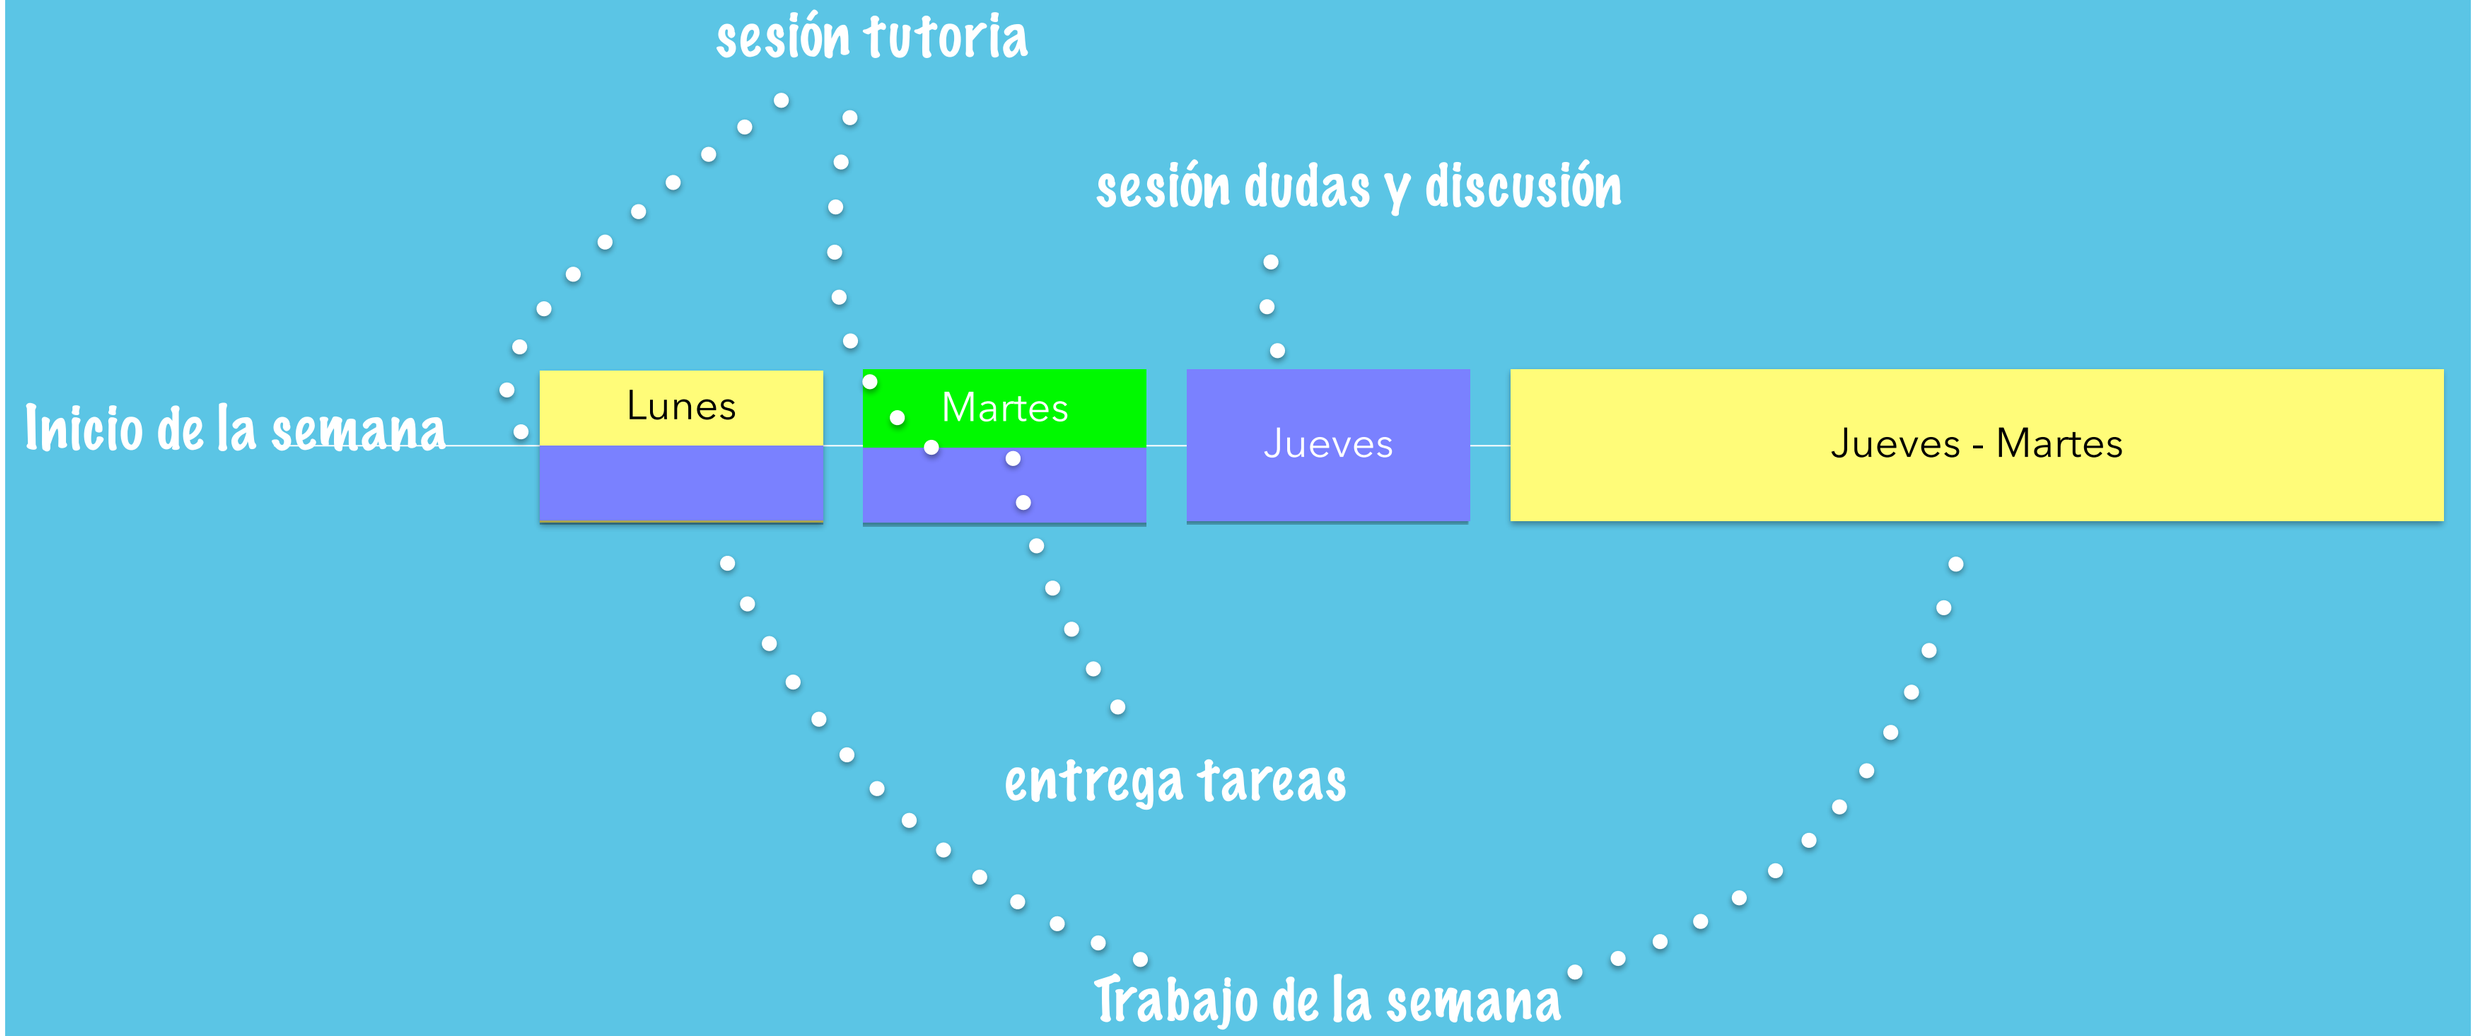
Organización del curso

Sesiones de dudas y discusión: Jueves 7:00 - 8:20

Sesiones de Tutoria: Lunes 17:00 - 18:00
Martes 17:00 - 18:00

Tutores: Luis Fernando Salas
Alejandro Medina
Raul de la Rosa
Kevin Herrera
Juan Diego Sanchez

Semana típica



Semanas

Semana 1	Introducción
Semana 2	Bandidos
Semana 3	MDPs
Semana 4	Iteraciones
Semana 5	Métodos de montecarlo
Semana 6	Diferencia temporal
Semana 7	Q-learning
Semana 8	Uso de opciones

Trabajo de la semana

- Trabajos prácticos (P&P)
- Quices
- Trabajos de programación

Trabajo de la semana

- Lecturas
- Videos

}

- Trabajos prácticos (P&P)
- Quices
- Trabajos de programación

Trabajo de la semana

- Lecturas
- Videos

- Trabajos prácticos (P&P)
- Quices
- Trabajos de programación

Afianzar conceptos y prueba de estrategias en modelos pequeños

Trabajo de la semana

- Lecturas
- Videos

- Trabajos prácticos (P&P)
- Quices

Afianzar conceptos y prueba de estrategias en modelos pequeños

- Trabajos de programación

Trabajos de programación individual para demostrar y afianzar el dominio de las estrategias de RL

Trabajos prácticos

Introducción de recompensas variables

El comportamiento de la función `expected_reward` requiere una división de sus responsabilidades. Por una parte, `expected_rewards` se encargará de calcular la recompensa obtenida para un brazo, dado por parámetro. La recompensa debe variar cada vez que se ejecuta un episodio. Para simular el cambio de la recompensa (dentro de un rango de valores conocidos) utilizaremos una función sinusoidal que nos da la recompensa obtenida del brazo como su recompensa inicial (i.e., la recompensa del brazo en la inicialización del bandido) multiplicado por el seno del paso actual. Es decir, para la iteración i, la recompensa del brazo j es:

$$r_i(j) = r_1(j) * \sin(i)$$

donde r_1 es la recompensa definida al crear el brazo, guardada en el atributo `arms`.

La recompensa se debe guardar (agregando el nuevo valor a la lista) en el atributo `episode_rewards` para el brazo dado. Este valor también debe ser retornado por la función.

In [ ]:
```
# Pruebas de la función expected_rewards

bandit = Bandit()
```

In [ ]:
```
#Pruebas adicionales
```

Deben complementar las pruebas para asegurarse que el comportamiento es es el esperado

Trabajos prácticos

Todos los tutoriales tienen ejemplos de las pruebas que pueden ser inspiración para sus propias pruebas

In [ ]:

```
b = Bandit()

### BEGIN TEST
from functools import reduce

try:
    b.occurrences
except:
    print("El atributo occurences no esta definido en el programa")
assert len(b.occurrences) == 10, "Las ocurrencias se deben calcular para cada brazo en una l
assert reduce(lambda x, y: x+y, b.occurrences) == 0, "Todas las occurencias se deben inicial

try:
    b.cumulative_rewards
except:
    print("El atributo cumuative_rewards no esta definido en el programa")
assert len(b.cumulative_rewards) == 10, "Las recompensas acumuladas se deben calcular para c
assert reduce(lambda x, y: x+y, b.cumulative_rewards) == 0, "Todos los valores de recompensa

try:
    b.expected_reward
except:
    print("La función expected_reward no esta implementada")

b.occurences = [0 for i in range(10)]
b.cumulative_reward = [0 for i in range(10)]
b.rewards = [0 for i in range(10)]
reward = b.expected_reward(2)

assert reduce(lambda x, y: x+y, b.cumulative_rewards) != 0, "La recompensa acumulada debe ca
assert reduce(lambda x, y: x+y, b.rewards) == reward, "La recompensa del brazo debe correspo

### END TEST
```

Trabajos prácticos

Los trabajos prácticos tienen un **máximo** de **5 entregas**

- Las entregas **no** son para debuggear los programas
- No deben programar para pasar pas pruebas, los programas deben funcionar en **todos los casos**
- Si tienen problemas con sus entregas, acudan al foro y los tutores

Trabajos prácticos

Los trabajos prácticos tienen un **máximo** de **5 entregas**

- Las entregas **no** son para debuggear los programas
- No deben programar para pasar pas pruebas, los programas deben funcionar en **todos los casos**
- Si tienen problemas con sus entregas, acudan al foro y los tutores



Otros estudiantes pueden haber resuelto ya ese mismo problema.

Proyecto de programación

Semana 1y3	Semana 5	Semana 8
Conformación de grupos de dos personas	Definición componentes básicos de la solución - Espacio de estados - Acciones del agente - Recompensas del agente	Entrega final - Código - Agente entrenado - Video de la ejecución del agente - Reporte



Entrega el Viernes de la semana 8

Conformación de grupos



correo **uniandes**

solo **una persona** debe llenar el formulario

Uso de IA generativa

El propósito del curso es **entender el funcionamiento** de los agentes de aprendizaje por refuerzo por medio de la **construcción** incremental de sus propiedades. Por lo tanto el uso de herramientas externas (IA generativa) para el desarrollo de las actividades **no esta permitido**

"Al presentar la solución de esta evaluación, yo, [nombre y apellido], con código [#], declaro que no he utilizado inteligencia artificial u otros medios no autorizados para resolverla. Soy consciente de que el uso indebido de dichas herramientas constituye una falta grave y acepto las consecuencias académicas que puedan derivarse de un acto de fraude en esta evaluación

Aplicaciones del aprendizaje por refuerzo

Aplicaciones del Aprendizaje por Refuerzo

0

Join by Web

PollEv.com/nicolascardozo733

Join by Text

Send **nicolascardozo733** and your message to **22333**

Join by QR code

Scan with your camera app

¿Porqué aprendizaje por refuerzo?

Propiedades fundamentales/ deseables del aprendizaje por refuerzo

Propiedades fundamentales/ deseables del aprendizaje por refuerzo

En un **mundo desconocido**, la única alternativa real de solución es la exploración

Propiedades fundamentales/ deseables del aprendizaje por refuerzo

En un **mundo desconocido**, la única alternativa real de solución es la exploración

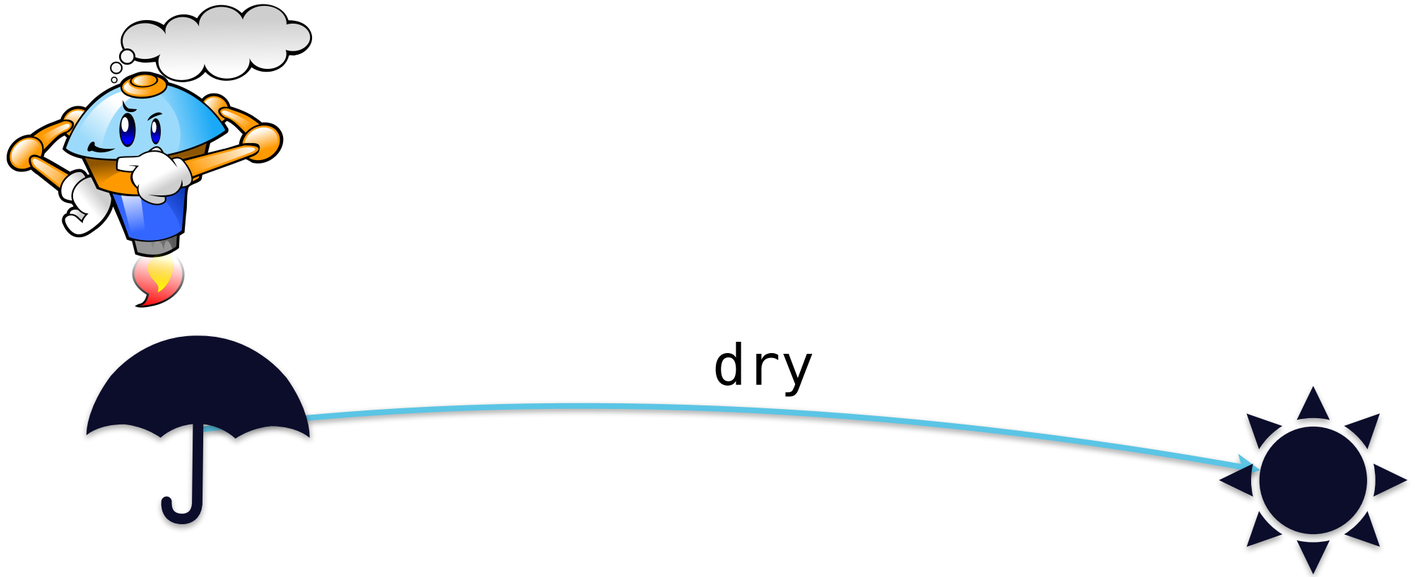
La evaluación **elimina** la dependencia de los datos.

Propiedades fundamentales/ deseables del aprendizaje por refuerzo

En un **mundo desconocido**, la única alternativa real de solución es la exploración

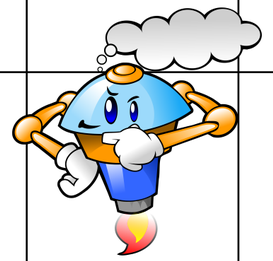
La evaluación **elimina** la dependencia de los datos.

Este modelo me *permite* actualizar el **comportamiento** de los agentes continuamente


dry

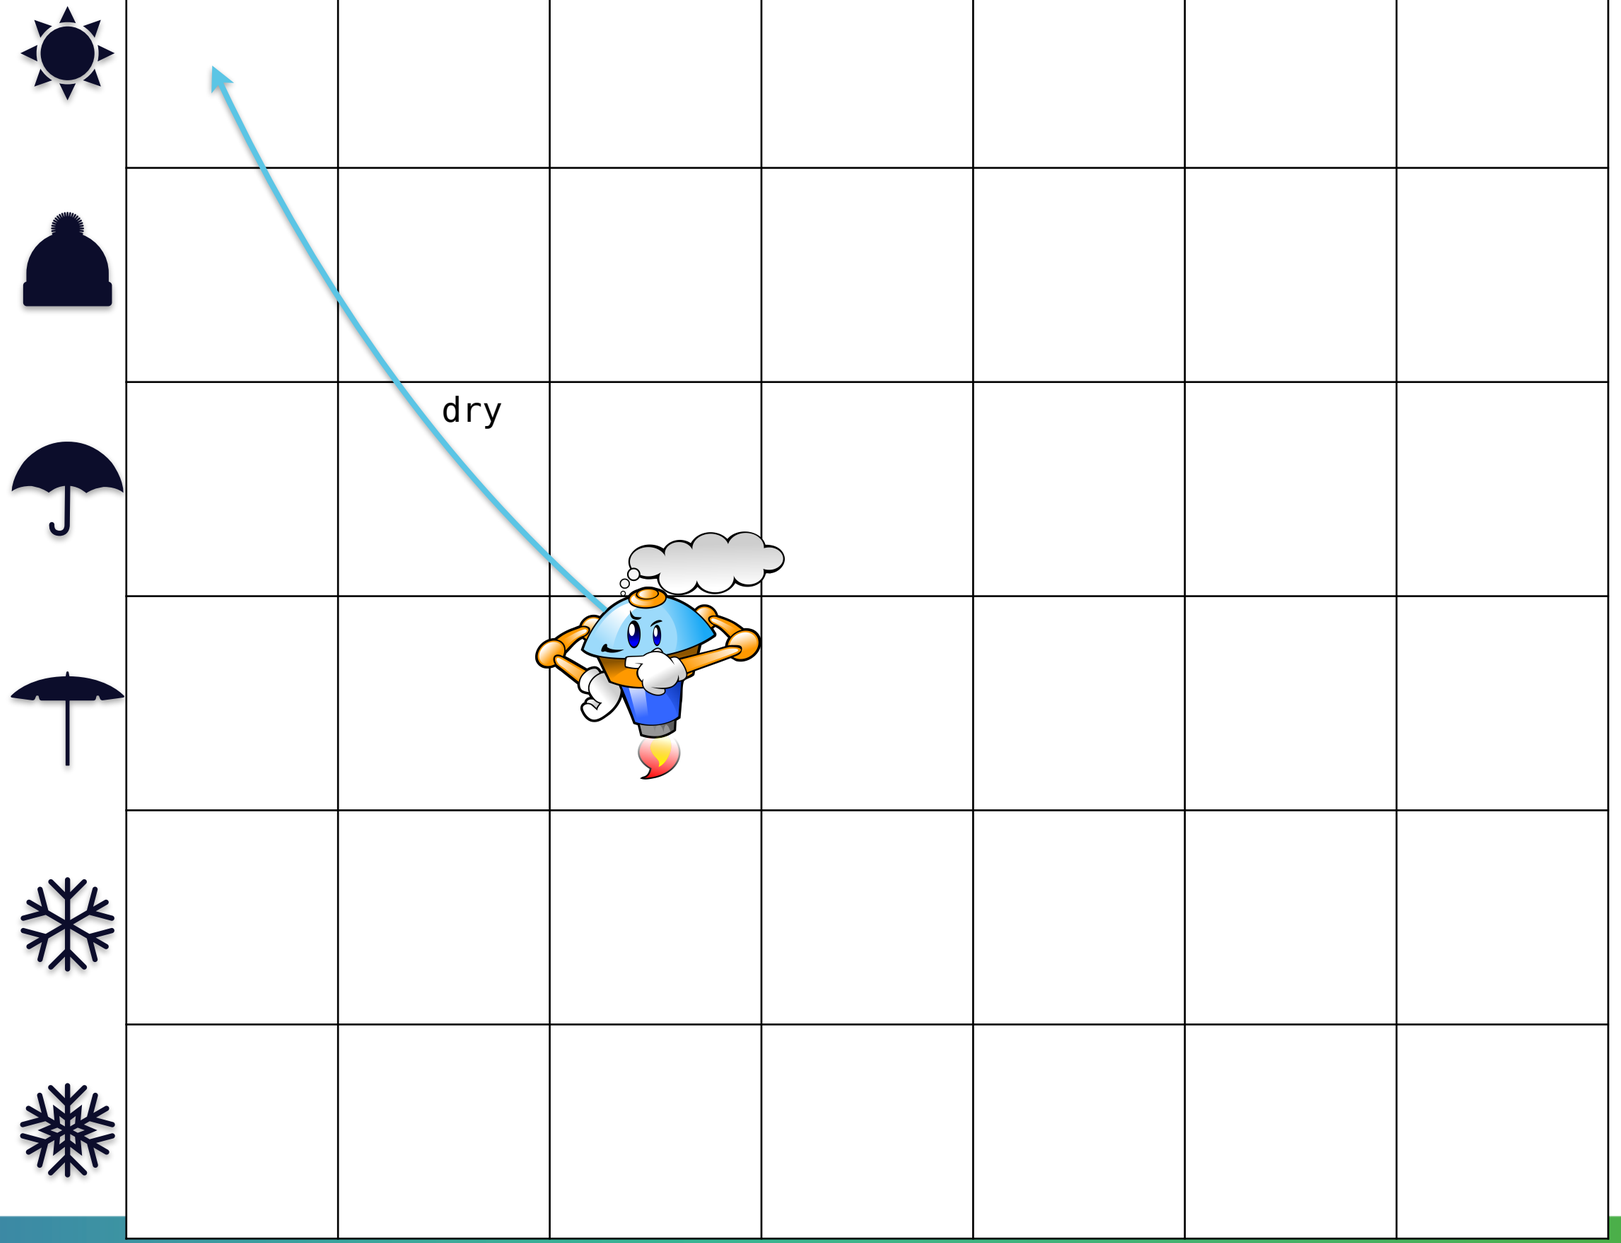
Acciones

Estados



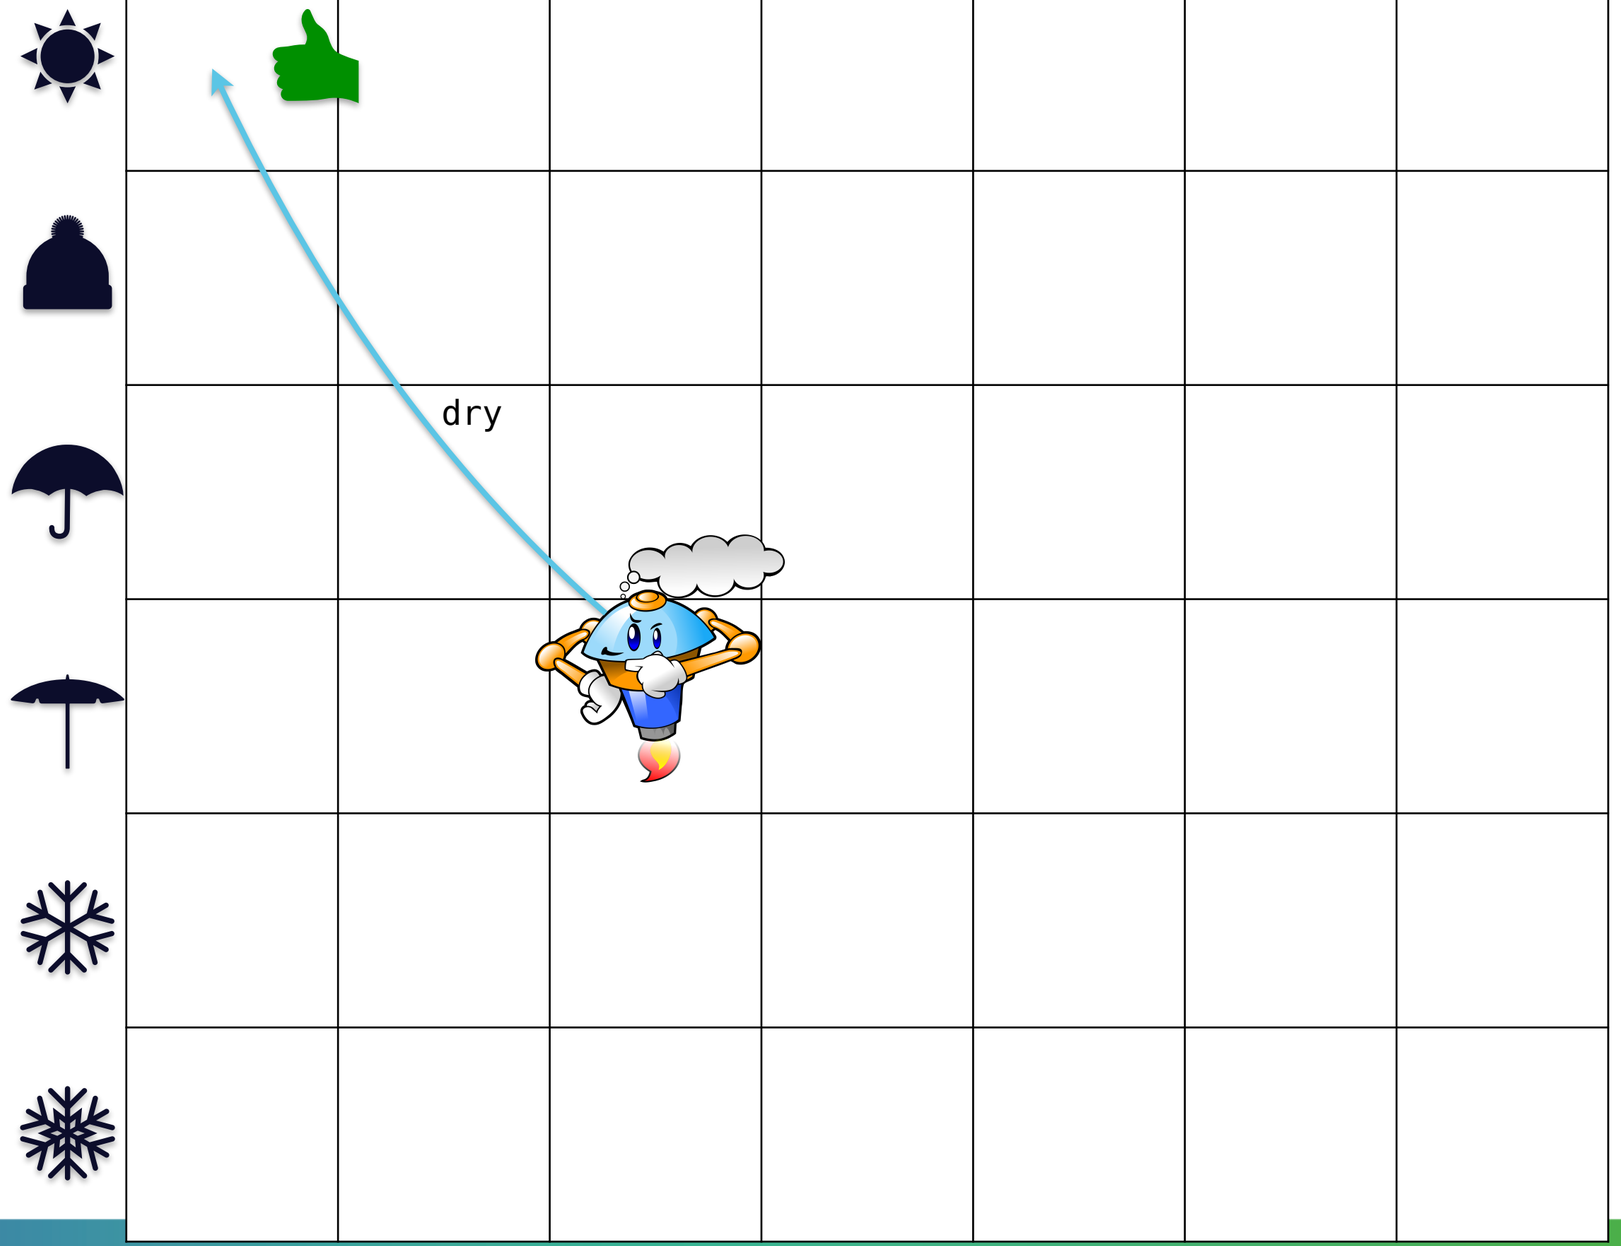
Acciones

Estados



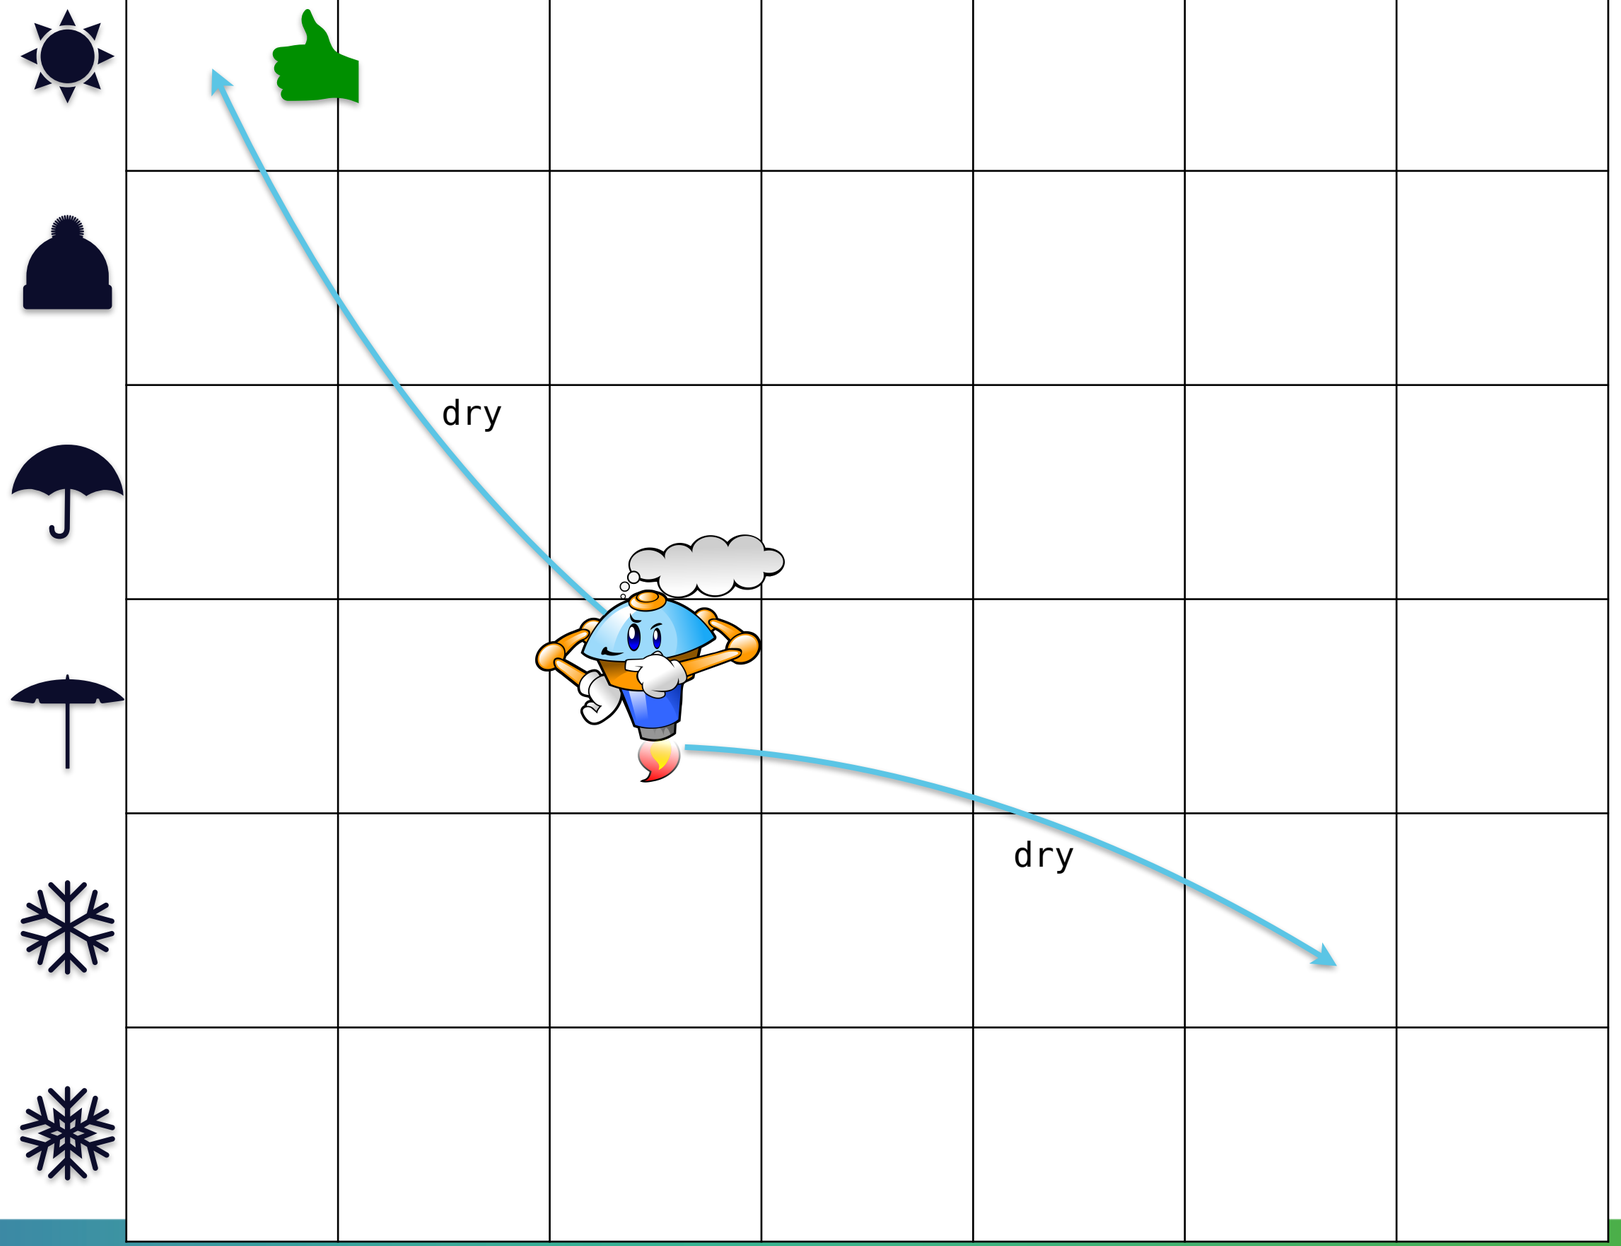
Acciones

Estados



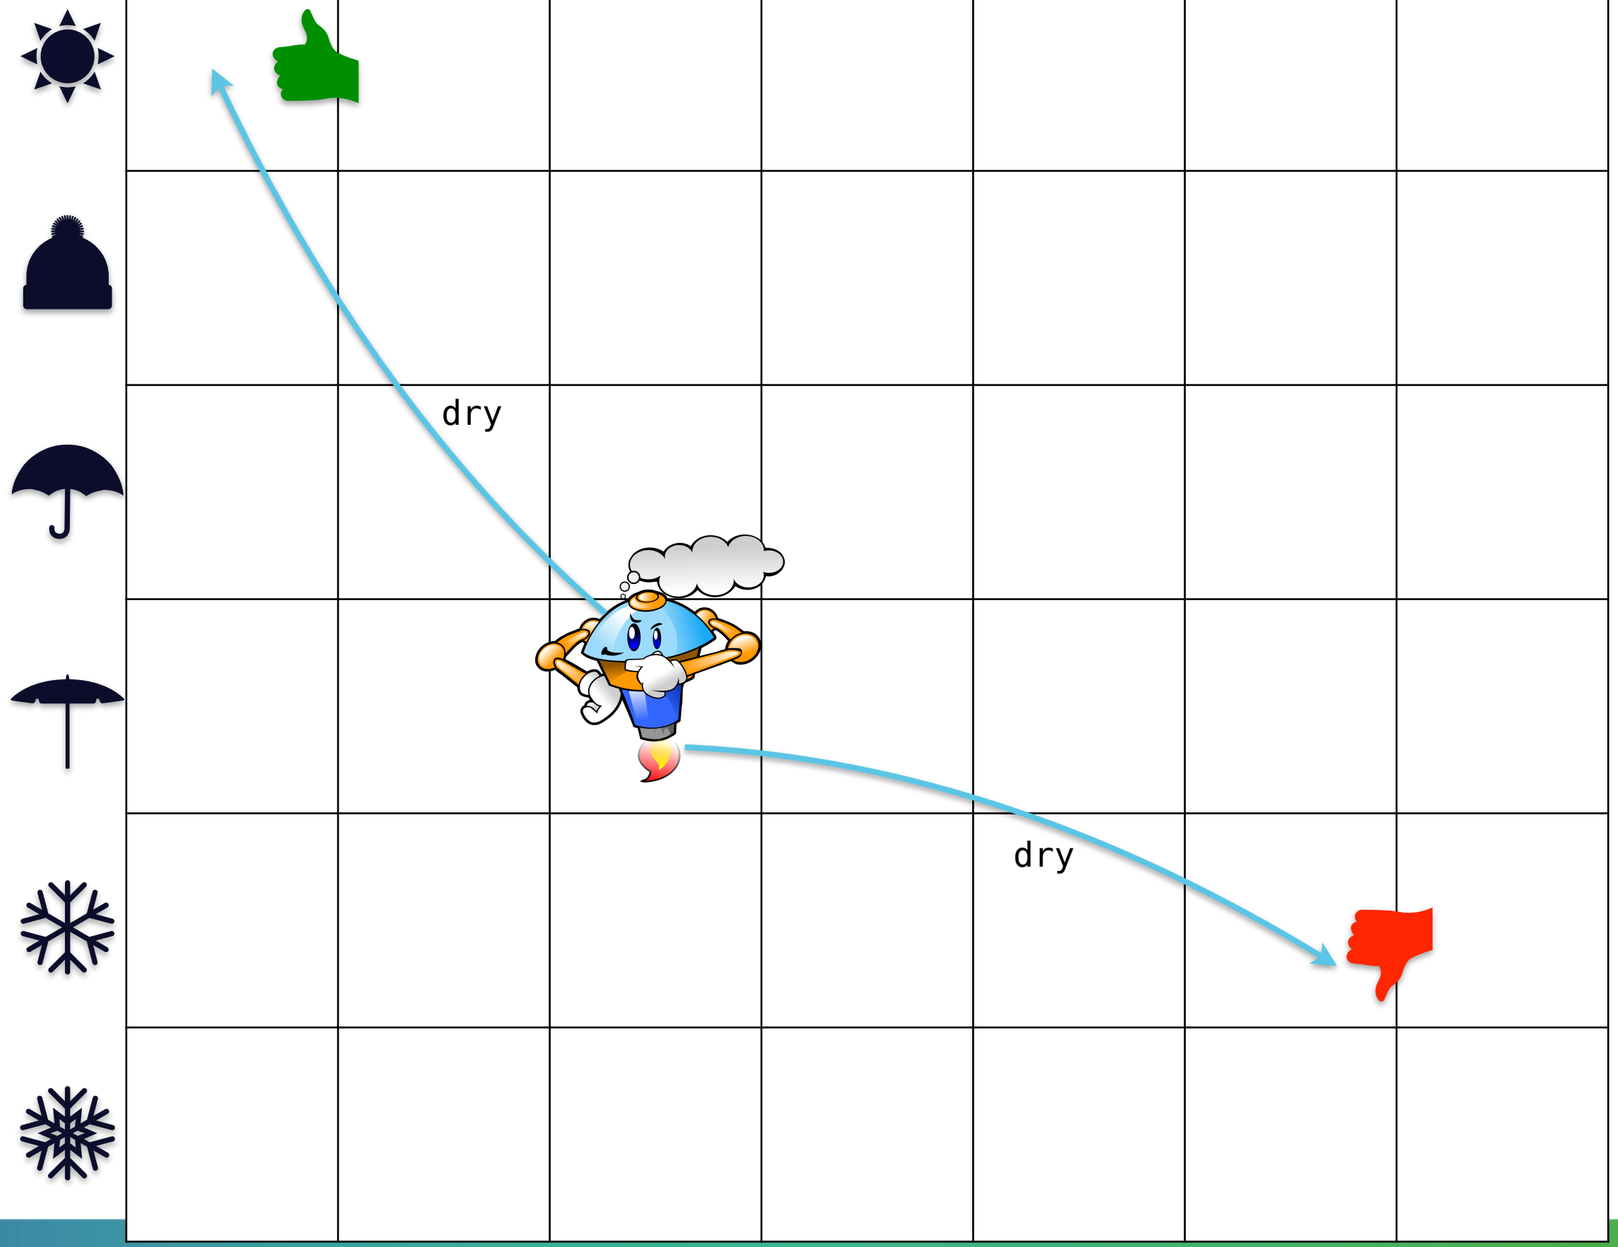
Acciones

Estados



Acciones

Estados



































































DANGER



ZONE

Problemas del aprendizaje por refuerzo

Problemas del aprendizaje por refuerzo

Alta dimensionalidad de los sistemas de estados

Problemas del aprendizaje por refuerzo

Alta dimensionalidad de los sistemas de estados

Tiempo de aprendizaje

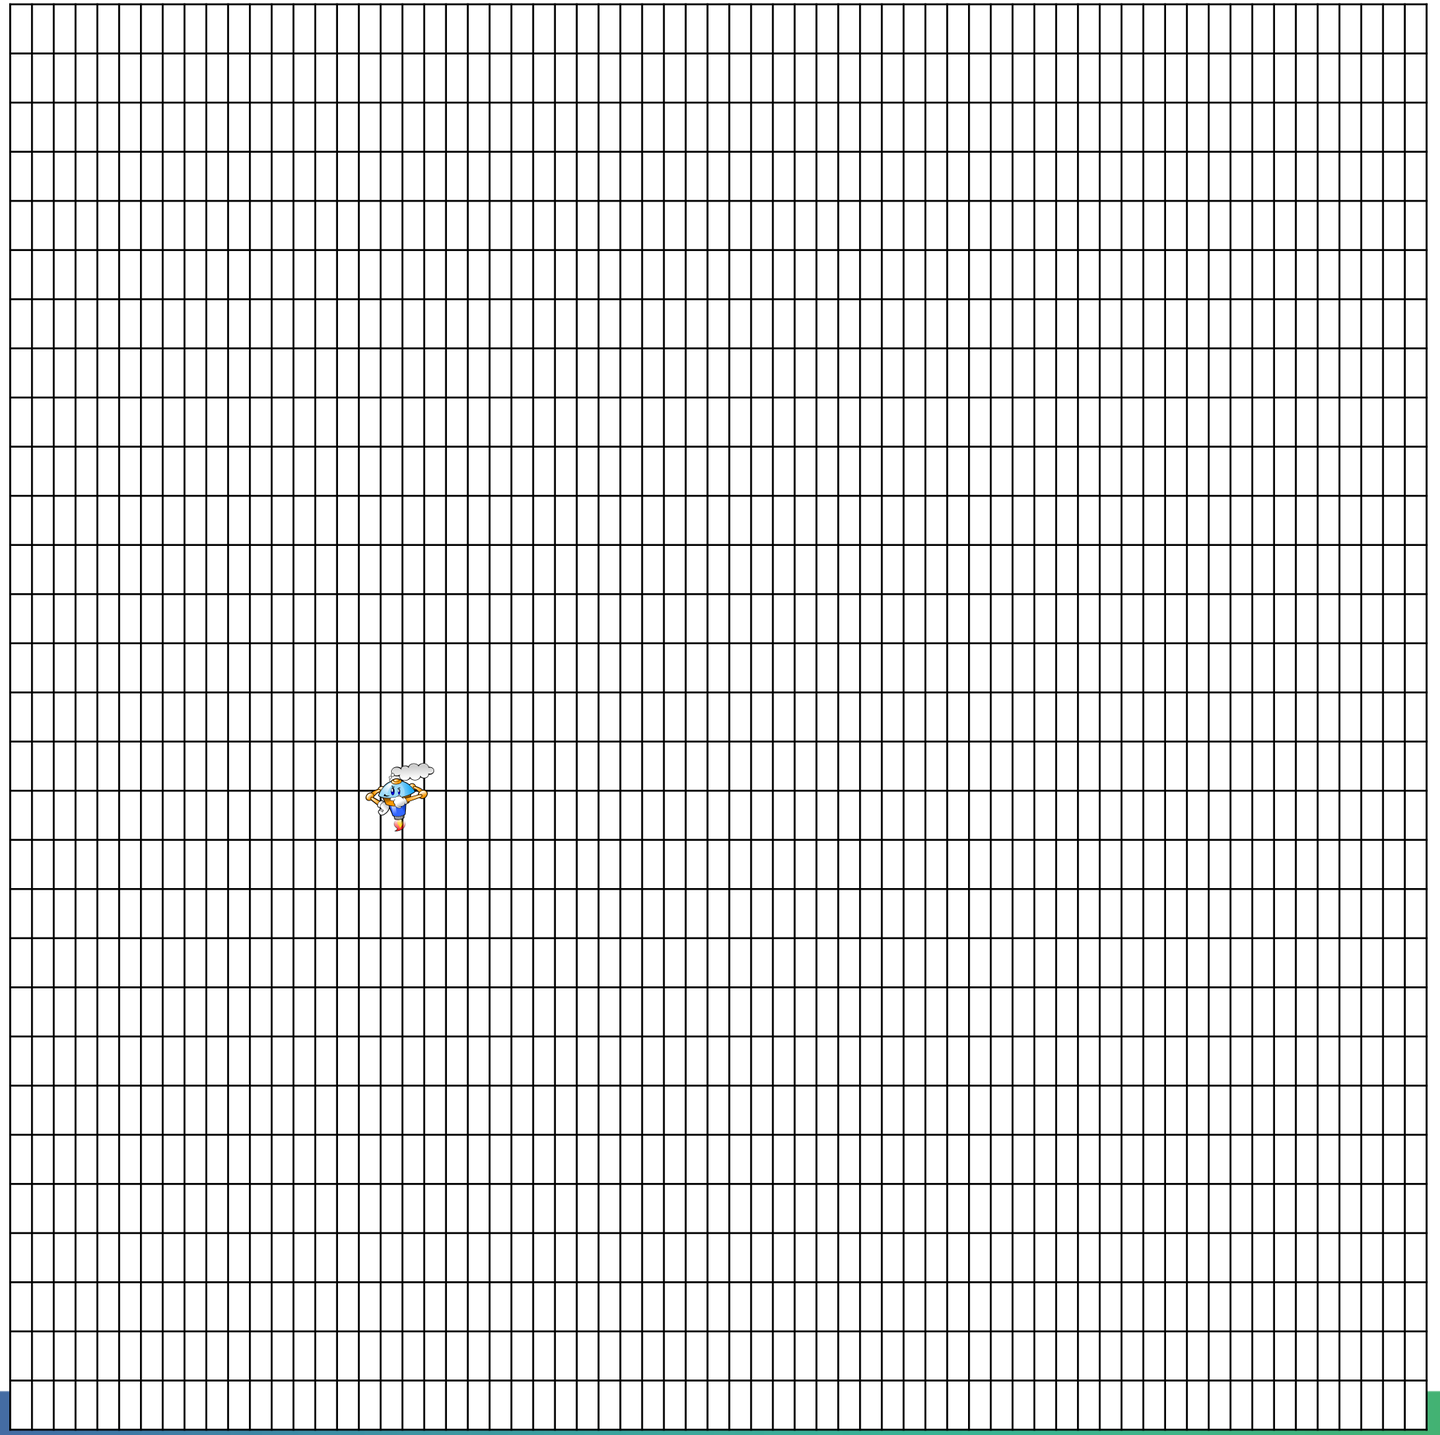
Problemas del aprendizaje por refuerzo

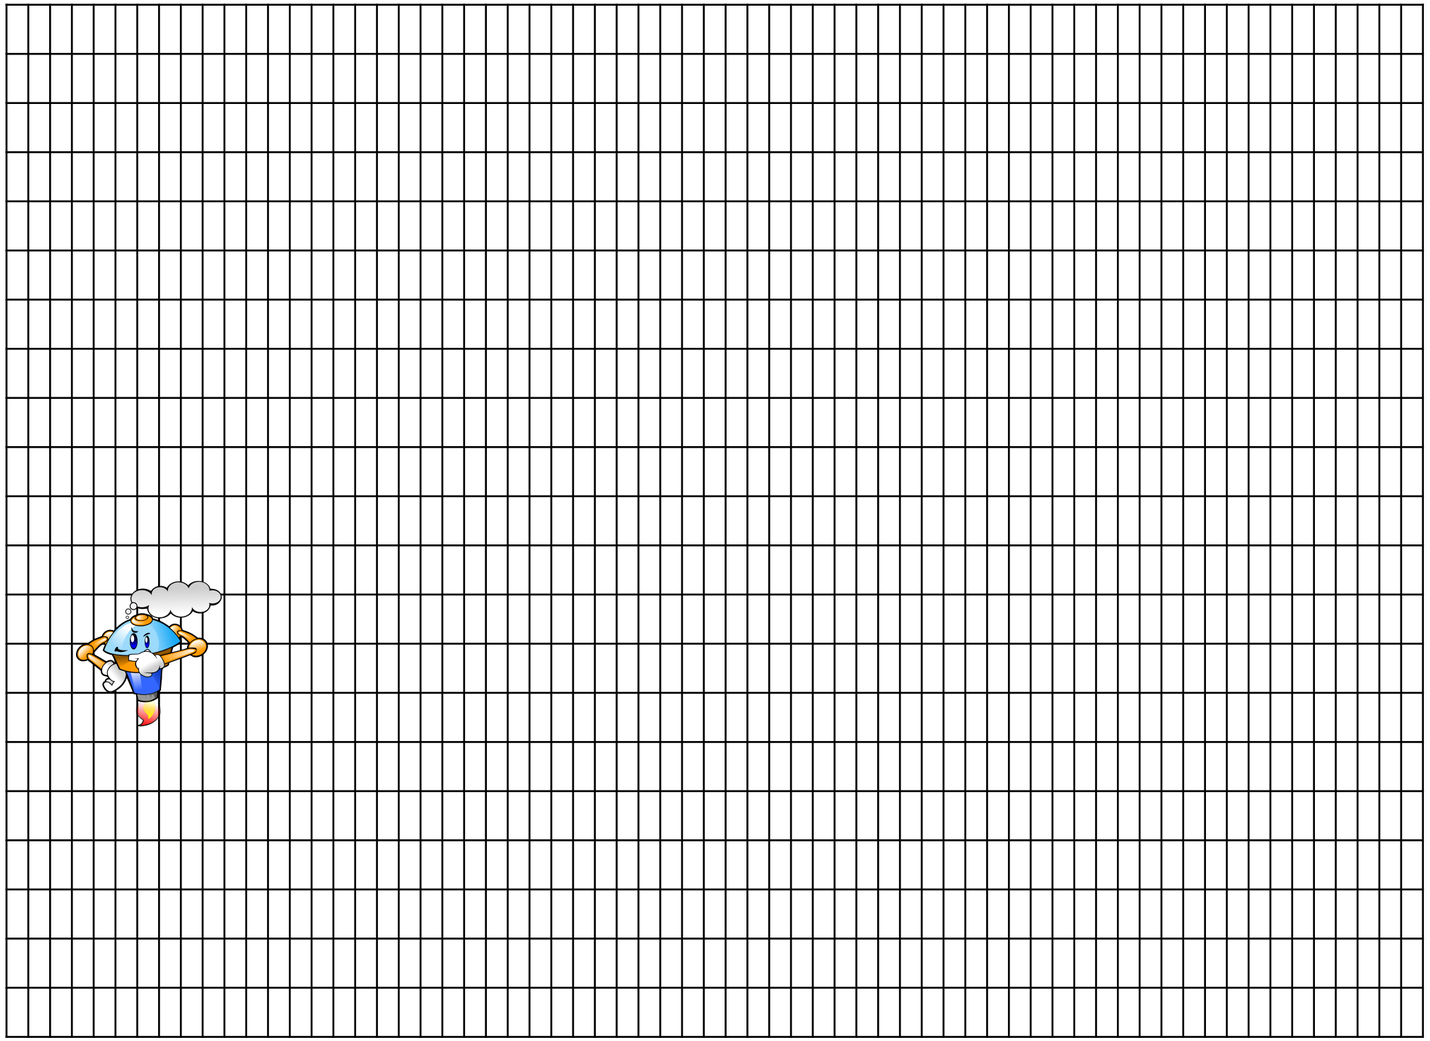
Alta dimensionalidad de los sistemas de estados

Tiempo de aprendizaje

Observabilidad de los ambientes







Los agentes escogen la acción **óptima** para cada estado



Los agentes escogen la acción **óptima** para cada estado



Los agentes escogen la acción **óptima** para cada estado **?**

Conclusión

Join by Web **PollEv.com/nicolascardozo733** Join by Text Send **nicolascardozo733** to **22333**

¿Cuándo usar RL?

0

Siempre	**(A)**
Si es necesario aprender	**(B)**
Cuando se tiene un objetivo claro en el sistema	**(C)**
Cuando tengo una descripción completa del sistema	**(D)**
En problemas pequeños	**(E)**
Nunca	**(F)**
Otros	**(G)**

Universidad de los Andes | Facultad de Ingeniería

RECURSO EDUCATIVO DIGITAL

AUTOR(ES) DEL GUION

Profesor Nicolás Cardozo

EQUIPO TÉCNICO

Presentador Nicolás Cardozo

Producción Nicolás Cardozo

Postproducción Nicolás Cardozo

Facultad de Ingeniería
Departamento de Ingeniería de Sistemas y Computación

Vicerrectoría Académica
Conecta-TE, Centro de Innovación en Tecnología y Educación

Universidad de los Andes

Bogotá, Colombia
Febrero 2023