Universidad de los Andes | Facultad de Ingeniería

Aprendizaje por Refuerzo













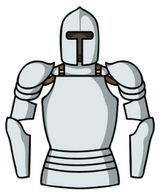












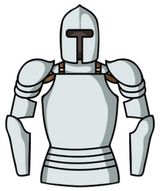








1



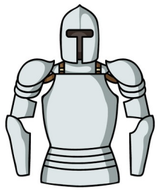








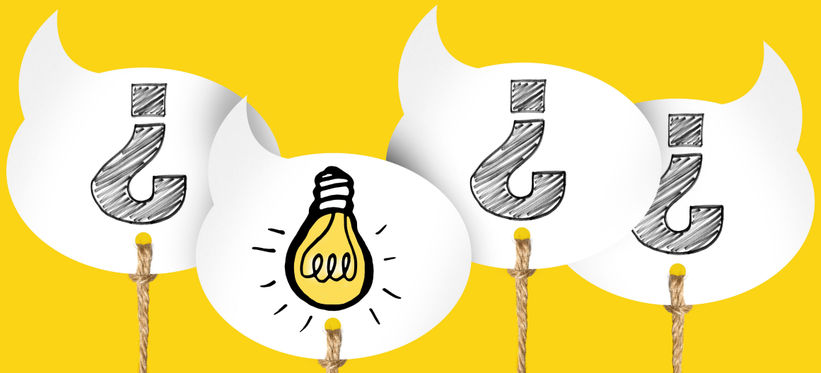
1



0



Cuál es la mejor puerta



Bandidos de K-brazos

Algoritmos de bandidos

- ϵ-greedy
- UCB (Upper Confidence Bound)
- Bernoulli (Thompson sampling)

Algoritmos de bandidos

- ε-greedy
- UCB (Upper Confidence Bound)
- Bernoulli (Thompson sampling)

```
if p < ε then
     random_action
else
     best_action
```

Algoritmos de bandidos

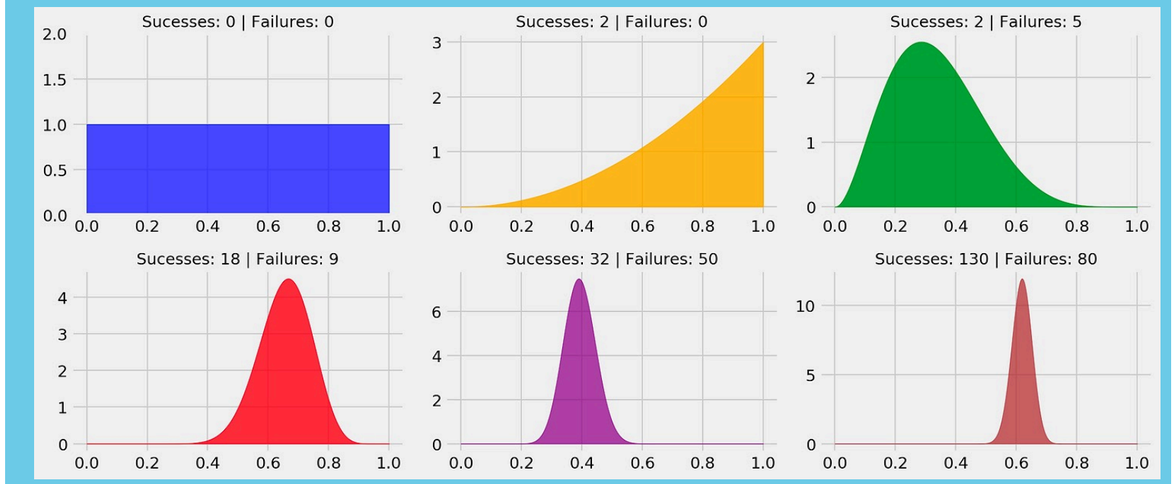
- ε-greedy
- UCB (Upper Confidence Bound)
- Bernoulli (Thompson sampling)

```
UCB=estimated mean reward + exploration bonus
```

$$A_t = \max_a \left(Q_{t(a)} + c\sqrt{\frac{ln(t)}{N_t(a)}} \right)$$

Algoritmos de bandidos

- ε-greedy
- UCB (Upper Confidence Bound)
- Bernoulli (Thompson sampling)



$$\rho = N\mu^* - \sum_{t=1}^{N} \hat{r}_t$$

arrepentimiento

$$\rho = N\mu^* - \sum_{t=1}^{N} \hat{r}_t$$

recompensa

arrepentimiento

recompensa promedio maximal

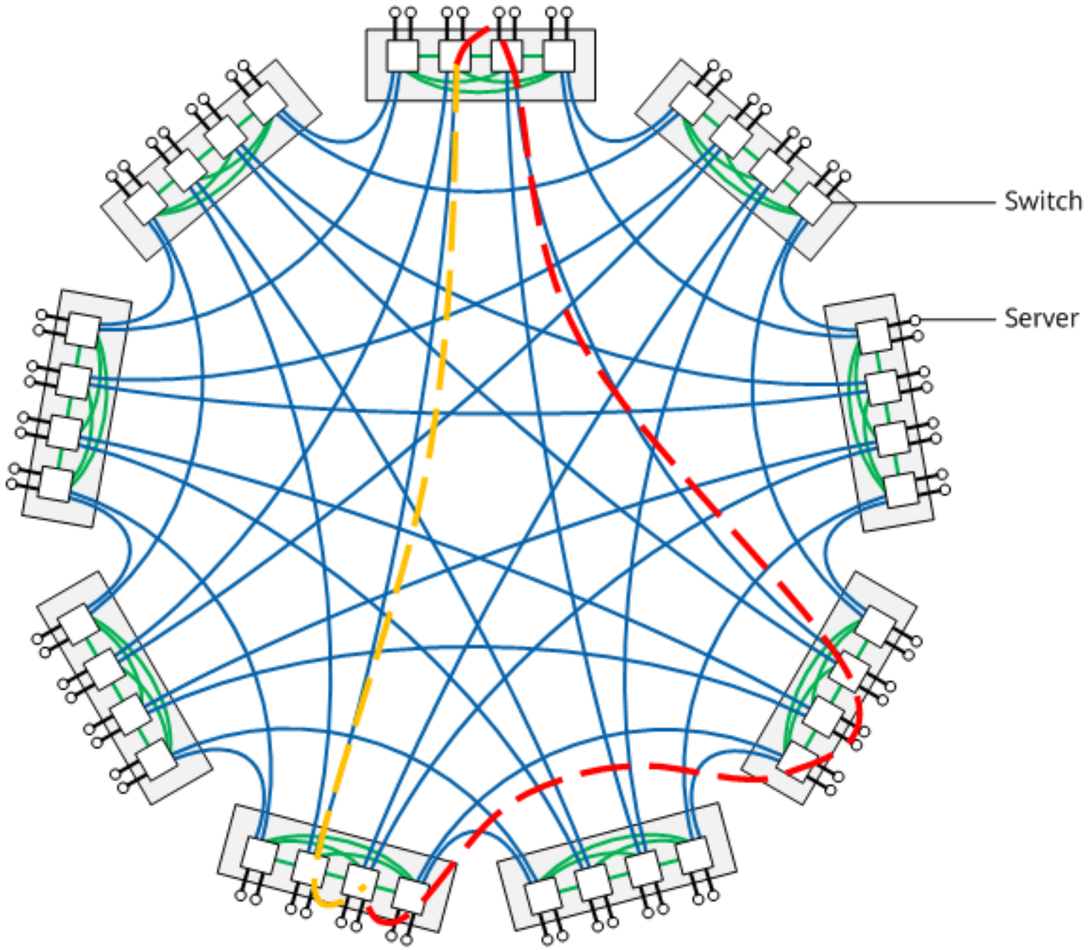
$$\rho = N\mu^* - \sum_{t=1}^{N} \hat{r}_t$$

recompensa

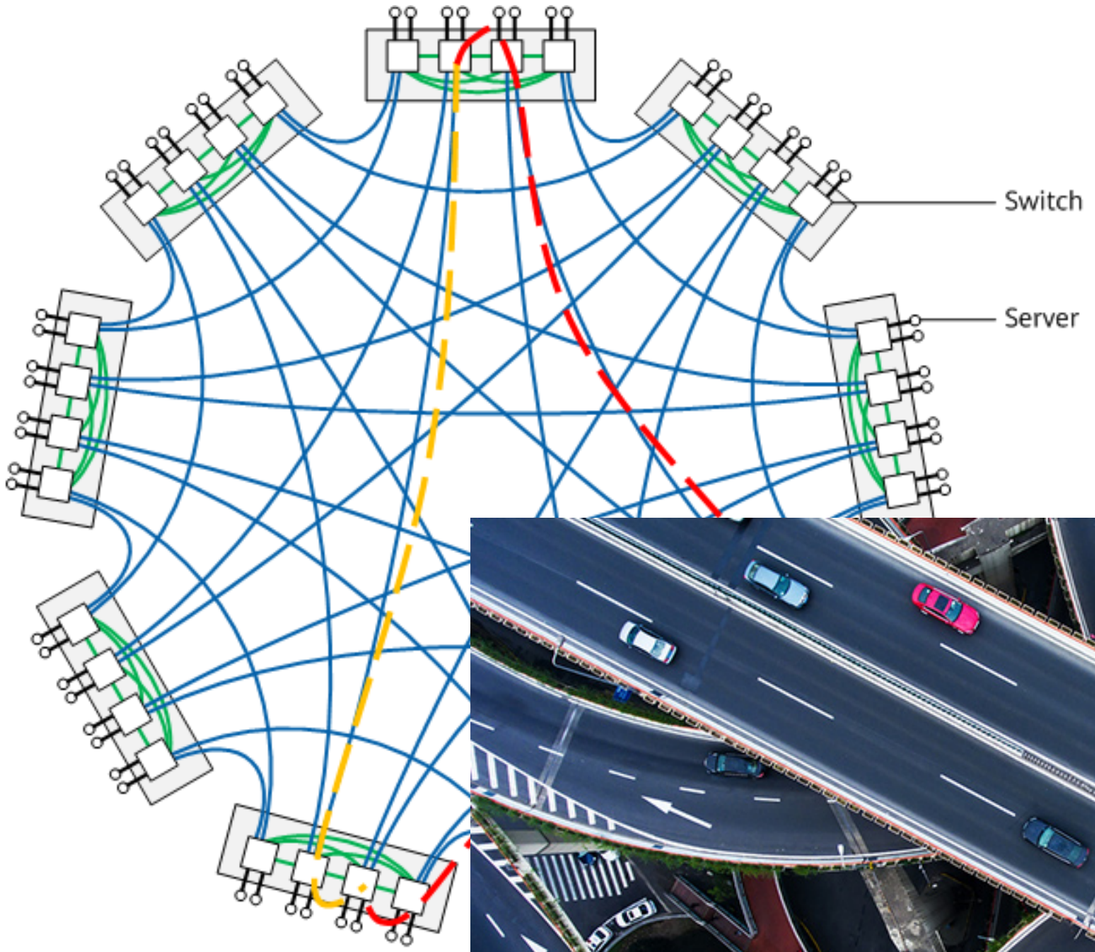
arrepentimiento

Aplicaciones

Enrutamiento dinámico

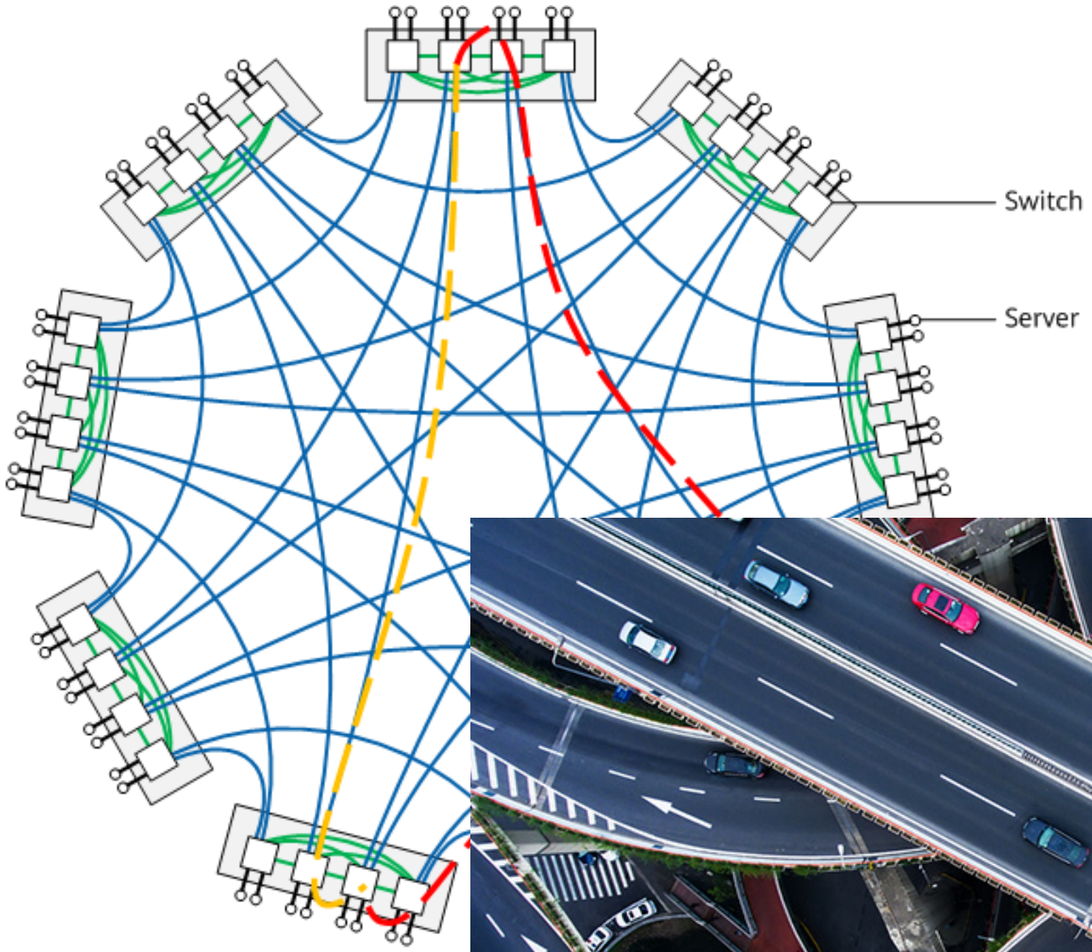


Enrutamiento dinámico





Enrutamiento dinámico







Trabajo de la semana



P&P 2.1

Existen cuatro caminos (c1, c2, c3, c4) entre las ciudades New Malia y Rose Hills. Cada uno de los caminos tiene un puente que puede estar abierto o cerrado. Si el puente está cerrado, no es posible pasar por el camino y por lo tanto no llegar a la ciudad. Como transportador entre las dos ciudades, usted debe hacer un viaje por hora, en la jornada laboral de 7 de la mañana (7h) a las 8 de la noche (20h). Para seleccionar el camino a escoger, teniendo cuenta su afinidad por los números utiliza una fórmula. Escogerá el camino a utilizar de acuerdo a la cantidad de factores en la descomposición por números primos de la hora en la que se hace el viaje (e.g., 8 tienen como descomposición (2, 2, 2), tomando el camino c3). Tomar cada uno de los caminos tiene una recompensa asociada. 18 para c1, 8 para c2, 16 para c3 y 12 para c4. Adicionalmente sabemos que el puente para el camino a tomar estará cerrado si la hora del transporte es múltiplo de 4. Si el puente del camino escogido está cerrado, la recompensa del viaje será 0.

Bajo estas condiciones queremos determinar el valor estimado total de cada uno de los caminos.

$$Q_n + \frac{1}{n(a)}(r_n - Q_n)$$

	c1	c2	c3	c4
7	18			
8			0	
9		8		
10		8		
11	18			
12			0	
13	18			
14		8		
15		8		
16				0
17	18			
18			5,33333333333333	
19	18			
20			4	



P&P 2.2

Suponga que vamos a ofrecer un sistema de recomendación para películas dentro de una plataforma de alquiler de películas por internet. El sistema recomienda cuatro películas (p1, p2, p3, p4) a los clientes (20 en nuestro caso), que pagarán el valor de la película más una propina variable si esta les gusta. Sin embargo, los usuarios no pagarán nada si la película no les gusta.

Queremos calcular el valor estimado del alquiler de las películas (la recompensa) si todas las películas tienen un valor inicial de 10$.

Sabemos que a los usuarios 1, 3, 4, 11, 12, 13 y 18 no les gustará la película. Todos los otros clientes gustarán de la película recomendada y darán una propina del 50% de valor igual al número de cliente por número de la película. Además, sabemos que las películas serán recomendadas en el siguiente orden [4,2,3,3,3,1,4,2,1,2,3,3,2,2,3,4,4,4,3,1] para los clientes.

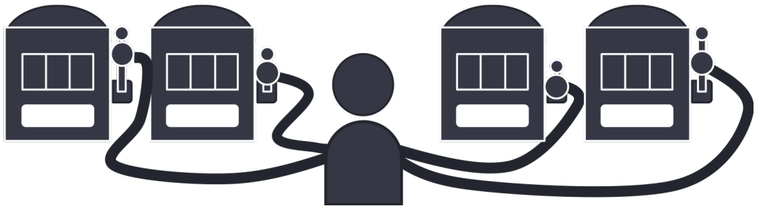
Suponga un valor de paso de 0.1

Bajo estas condiciones queremos determinar el valor estimado total del valor de las películas.

pelicula	Cliente	p1	p2	p3	p4
4	**1**				0
2	**2**		12		
3	**3**			0	
3	**4**			0	
3	**5**			17,5	
1	**6**	13			
4	**7**				24
2	**8**		18		
1	**9**	14,5			
2	**10**		20		
3	**11**			0	
3	**12**			0	
2	**13**		0		
2	**14**		24		
3	**15**			32,5	
4	**16**				42
4	**17**				44
4	**18**				0
3	**19**			38,5	
1	**20**	20			
		11,65	12,02	12,71	15,02

$$Q_{n+1} = (1-\alpha)^n Q_1 + \sum_{i=1}^{n} \alpha(1-\alpha)^{n-i} r_i$$

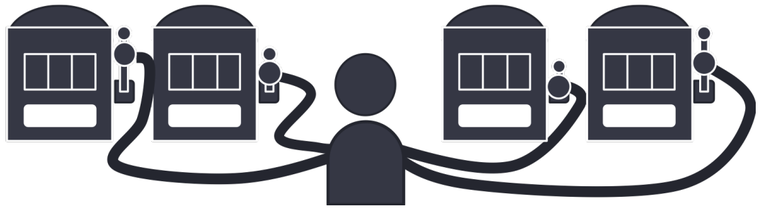
Semana 1y2	Semana 5	Semana 8
Conformación de grupos	Definición componentes básicos de la solución	Entrega final - Código - Agente entrenado - Video de la ejecución del agente - Reporte



Bandidos con epsilon decay

Los bandidos comienzan con un epsilon apto para la exploración.

A media que avanzan los episodios el valor de epsilon cae, para dar prioridad a las acciones con mayor recompensa



Bandidos con recompensas variables

Los bandidos comienzan con un epsilon apto para la exploración.

Las recompensas del bandido son variables y por lo tanto toca definir el peso de los valores para determinar el comportamiento del bandido

$$Q_{n+1} = (1-\alpha)^n Q_1 + \sum_{i=1}^{n} \alpha(1-\alpha)^{n-i} r_i$$

Universidad de los Andes | Facultad de Ingeniería

RECURSO EDUCATIVO DIGITAL

AUTOR(ES)

Profesor Nicolás Cardozo

EQUIPO TÉCNICO

Presentador Nicolás Cardozo

Producción Nicolás Cardozo

Postproducción Nicolás Cardozo

Facultad de Ingeniería
Departamento de Ingeniería de Sistemas y Computación

Vicerrectoría Académica
Conecta-TE, Centro de Innovación en Tecnología y Educación

Universidad de los Andes

Bogotá, Colombia
Febrero 2023

Facultad de Ingeniería

Departamento de Ingeniería de Sistemas y Computación

Aprendizaje por refuerzo

Vicerrectoría Académica

Universidad de los Andes

(Abril/2024)

© - Derechos Reservados: La presente obra, y en general todos sus contenidos, se encuentran protegidos por las normas internacionales y nacionales vigentes sobre propiedad Intelectual, por lo tanto su utilización parcial o total, reproducción, comunicación pública, transformación, distribución, alquiler, préstamo público e importación, total o parcial, en todo o en parte, en formato impreso o digital y en cualquier formato conocido o por conocer, se encuentran prohibidos, y solo serán lícitos en la medida en que se cuente con la autorizaci previa y expresa por escrito de la Universidad de los Andes.

De igual manera, la utilización de la imagen de las personas, docentes o estudiantes, sin su previa autorización está expresamente prohibida. En caso de incumplirse con lo mencionado, se procederá de conformidad con los reglamentos y políticas de la universidad, sin perjuici las demás acciones legales aplicables.