Universidad de los Andes | Facultad de Ingeniería

Aprendizaje por Refuerzo

MDPs

```python
import random

table = [[[(1,0,1)], [(0.5, 0, 2), (0.5,1,2)]],
         [[(0.5, 0, 1), (0.5,1,1)], [(1, 2, -10)]],
         [None, None]]

env = MDP(table, (3,2), 0)

done = False
total_reward = 0
steps = 0
while not done:
    old_state = env.get_current_state()
    action = random.choice(env.get_possible_actions(old_state))
    reward, new_state = env.do_action(action)
    total_reward += reward
    print(f"Ejecutando la acción {action} desde el estado {old_state} al estado {new_state}")
    steps += 1
    done = env.is_terminal()
print(f"Ejecuto {steps} pasos y obtuvo una recompensa de {total_reward}")
```

```
Ejecutando la acción fast desde el estado 0 al estado 1
Ejecutando la acción slow desde el estado 1 al estado 1
Ejecutando la acción fast desde el estado 1 al estado 2
Ejecuto 3 pasos y obtuvo una recompensa de -7
```

Preguntas de reflexión

¿Qué puede concluir de la ejecución del MDP en cuanto a la cantidad de acciones que se ejejcutan? ¿Existe alguna diferencia?

Value and policy iteration

$$V^*(s) = \max_a \sum_{s'} T(s, a, s')[R(s, a, s') + \gamma V^*(s')]$$

¿Qué implica una iteración para el cálculo de valores?

s	a	s’	T(s,a,s’)	R(s,a,s’)
A	1	A	0	0
A	1	B	1	0
A	2	A	0	0
A	2	B	1	2
A	3	A	0.5	0
A	3	B	0.5	0
B	1	A	0.4	0
B	1	B	0.6	10
B	2	A	0	0
B	2	B	1	0
B	3	A	0.5	2
B	3	B	0.5	6

Considere el siguiente MDP en la tabla, con factor de descuento 1. Calcule los valores para V0, V1, V2 y V3 para cada uno de los estados A y B.

s	a	s’	T(s,a,s’)	R(s,a,s’)
A	1	A	0	0
A	1	B	1	0
A	2	A	0	0
A	2	B	1	2
A	3	A	0.5	0
A	3	B	0.5	0
B	1	A	0.4	0
B	1	B	0.6	10
B	2	A	0	0
B	2	B	1	0
B	3	A	0.5	2
B	3	B	0.5	6

Considere el siguiente MDP en la tabla, con factor de descuento 1. Calcule los valores para V0, V1, V2 y V3 para cada uno de los estados A y B.

$$V_1^1(A) = 0(0 + 1 \times 0) + 1(0 + 1 \times 0)$$
$$= 0$$
$$V_1^1(B) = 0.4(0 + 1 \times 0) + 0.6(10 + 1 \times 0)$$
$$= 6$$

$$V_1^2(A) = 0(0 + 1 \times 0) + 1(2 + 1 \times 0)$$
$$= 2$$
$$V_1^2(B) = 0(0 + 1 \times 0) + 1(0 + 1 \times 0)$$
$$= 0$$

$$V_1^3(A) = 0.5(0 + 1 \times 0) + 0.5(0 + 1 \times 0)$$
$$= 0$$
$$V_1^3(B) = 0.5(2 + 1 \times 0) + 0.5(6 + 1 \times 0)$$
$$= 4$$

s	a	s’	T(s,a,s’)	R(s,a,s’)
A	1	A	0	0
A	1	B	1	0
A	2	A	0	0
A	2	B	1	2
A	3	A	0.5	0
A	3	B	0.5	0
B	1	A	0.4	0
B	1	B	0.6	10
B	2	A	0	0
B	2	B	1	0
B	3	A	0.5	2
B	3	B	0.5	6

Considere el siguiente MDP en la tabla, con factor de descuento 1. Calcule los valores para V0, V1, V2 y V3 para cada uno de los estados A y B.

$$V_1^1(A) = 0(0 + 1 \times 0) + 1(0 + 1 \times 0)$$
$$= 0$$
$$V_1^1(B) = 0.4(0 + 1 \times 0) + 0.6(10 + 1 \times 0)$$
$$= 6$$

$$V_1^2(A) = 0(0 + 1 \times 0) + 1(2 + 1 \times 0)$$
$$= 2$$
$$V_1^2(B) = 0(0 + 1 \times 0) + 1(0 + 1 \times 0)$$
$$= 0$$

$$V_1^3(A) = 0.5(0 + 1 \times 0) + 0.5(0 + 1 \times 0)$$
$$= 0$$
$$V_1^3(B) = 0.5(2 + 1 \times 0) + 0.5(6 + 1 \times 0)$$
$$= 4$$

$$V_1(A) = 2$$
$$V_1(B) = 6$$

s	a	s’	T(s,a,s’)	R(s,a,s’)
A	1	A	0	0
A	1	B	1	0
A	2	A	0	0
A	2	B	1	2
A	3	A	0.5	0
A	3	B	0.5	0
B	1	A	0.4	0
B	1	B	0.6	10
B	2	A	0	0
B	2	B	1	0
B	3	A	0.5	2
B	3	B	0.5	6

Considere el siguiente MDP en la tabla, con factor de descuento 1. Calcule los valores para V0, V1, V2 y V3 para cada uno de los estados A y B.

$$V_2^1(A) = 0(0 + 1 \times 2) + 1(0 + 1 \times 6)$$
$$= 6$$
$$V_2^1(B) = 0.4(0 + 1 \times 2) + 0.6(10 + 1 \times 6)$$
$$= 10.4$$

$$V_2^2(A) = 0(0 + 1 \times 2) + 1(2 + 1 \times 6)$$
$$= 8$$
$$V_2^2(B) = 0(0 + 1 \times 2) + 1(0 + 1 \times 6)$$
$$= 6$$

$$V_2^3(A) = 0.5(0 + 1 \times 2) + 0.5(0 + 1 \times 6)$$
$$= 4$$
$$V_2^3(B) = 0.5(2 + 1 \times 2) + 0.5(6 + 1 \times 6)$$
$$= 8$$

s	a	s’	T(s,a,s’)	R(s,a,s’)
A	1	A	0	0
A	1	B	1	0
A	2	A	0	0
A	2	B	1	2
A	3	A	0.5	0
A	3	B	0.5	0
B	1	A	0.4	0
B	1	B	0.6	10
B	2	A	0	0
B	2	B	1	0
B	3	A	0.5	2
B	3	B	0.5	6

Considere el siguiente MDP en la tabla, con factor de descuento 1. Calcule los valores para V0, V1, V2 y V3 para cada uno de los estados A y B.

$$V_2^1(A) = 0(0 + 1 \times 2) + 1(0 + 1 \times 6)$$
$$= 6$$
$$V_2^1(B) = 0.4(0 + 1 \times 2) + 0.6(10 + 1 \times 6)$$
$$= 10.4$$

$$V_2^2(A) = 0(0 + 1 \times 2) + 1(2 + 1 \times 6)$$
$$= 8$$
$$V_2^2(B) = 0(0 + 1 \times 2) + 1(0 + 1 \times 6)$$
$$= 6$$

$$V_2^3(A) = 0.5(0 + 1 \times 2) + 0.5(0 + 1 \times 6)$$
$$= 4$$
$$V_2^3(B) = 0.5(2 + 1 \times 2) + 0.5(6 + 1 \times 6)$$
$$= 8$$

$$V_2(A) = 6$$
$$V_2(B) = 10{,}4$$

s	a	s’	T(s,a,s’)	R(s,a,s’)
A	1	A	0	0
A	1	B	1	0
A	2	A	0	0
A	2	B	1	2
A	3	A	0.5	0
A	3	B	0.5	0
B	1	A	0.4	0
B	1	B	0.6	10
B	2	A	0	0
B	2	B	1	0
B	3	A	0.5	2
B	3	B	0.5	6

Considere el siguiente MDP en la tabla, con factor de descuento 1. Calcule los valores para V0, V1, V2 y V3 para cada uno de los estados A y B.

$$V_3^1(A) = 0(0 + 1 \times 6) + 1(0 + 1 \times 10{,}4)$$
$$= 10{,}4$$
$$V_3^1(B) = 0.4(0 + 1 \times 6) + 0.6(10 + 1 \times 10{,}4)$$
$$= 8.64$$

$$V_3^2(A) = 0(0 + 1 \times 6) + 1(2 + 1 \times 10{,}4)$$
$$= 12{,}4$$
$$V_3^2(B) = 0(0 + 1 \times 6) + 1(0 + 1 \times 10{,}4)$$
$$= 10{,}4$$

$$V_3^3(A) = 0{,}5(0 + 1 \times 6) + 0{,}5(0 + 1 \times 10{,}4)$$
$$= 8{,}2$$
$$V_3^3(B) = 0{,}5(2 + 1 \times 6) + 0{,}5(6 + 1 \times 10{,}4)$$
$$= 16{,}2$$

s	a	s’	T(s,a,s’)	R(s,a,s’)
A	1	A	0	0
A	1	B	1	0
A	2	A	0	0
A	2	B	1	2
A	3	A	0.5	0
A	3	B	0.5	0
B	1	A	0.4	0
B	1	B	0.6	10
B	2	A	0	0
B	2	B	1	0
B	3	A	0.5	2
B	3	B	0.5	6

Considere el siguiente MDP en la tabla, con factor de descuento 1. Calcule los valores para V0, V1, V2 y V3 para cada uno de los estados A y B.

$$V_3^1(A) = 0(0 + 1 \times 6) + 1(0 + 1 \times 10{,}4)$$
$$= 10{,}4$$
$$V_3^1(B) = 0.4(0 + 1 \times 6) + 0.6(10 + 1 \times 10{,}4)$$
$$= 8.64$$

$$V_3^2(A) = 0(0 + 1 \times 6) + 1(2 + 1 \times 10{,}4)$$
$$= 12{,}4$$
$$V_3^2(B) = 0(0 + 1 \times 6) + 1(0 + 1 \times 10{,}4)$$
$$= 10{,}4$$

$$V_3^3(A) = 0{,}5(0 + 1 \times 6) + 0{,}5(0 + 1 \times 10{,}4)$$
$$= 8{,}2$$
$$V_3^3(B) = 0{,}5(2 + 1 \times 6) + 0{,}5(6 + 1 \times 10{,}4)$$
$$= 16{,}2$$

$$V_2(A) = 12{,}4$$
$$V_2(B) = 16{,}2$$

¿Cuándo se terminan de calcular los valores de los estados?

¿Es posible que el cálculo de los valores sea más rápido?

$$V^*(s) = \max_a Q^*(s, a)$$

$$Q^*(s, a) = \sum_{s'} T(s, a, s')[R(s, a, s') + \gamma V^*(s')]$$

$$V^*(s) = \max_a Q^*(s, a)$$

$$Q^*(s, a) = \sum_{s'} T(s, a, s')[R(s, a, s') + \gamma V^*(s')]$$

ruido

$$V^*(s) = \max_a Q^*(s,a)$$

$$Q^*(s,a) = \sum_{s'} T(s,a,s')[R(s,a,s') + \gamma V^*(s')]$$

recompensa

ruido

$$V^*(s) = \max_a Q^*(s,a)$$

$$Q^*(s,a) = \sum_{s'} T(s,a,s')[R(s,a,s') + \gamma V^*(s')]$$

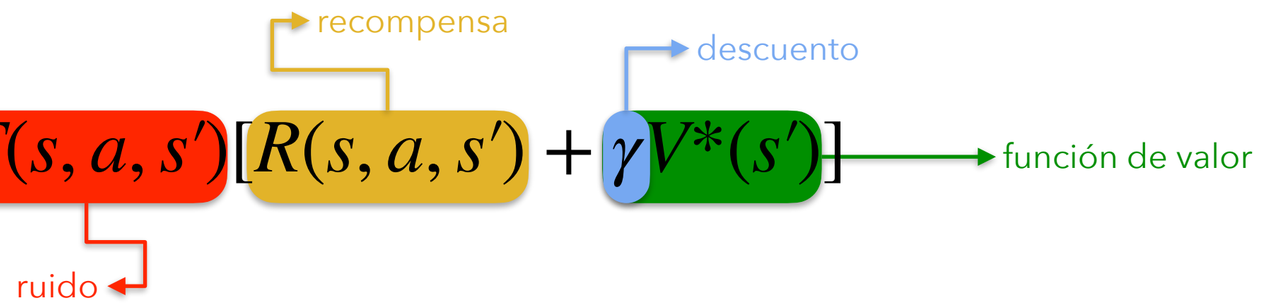
recompensa

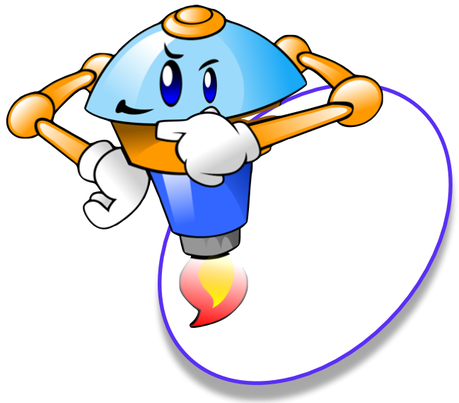
ruido

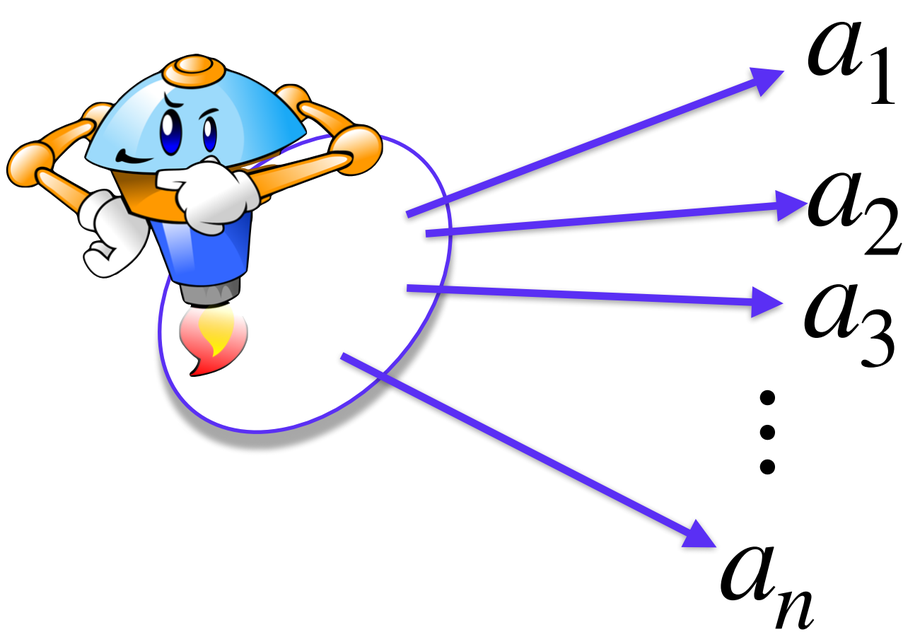
función de valor

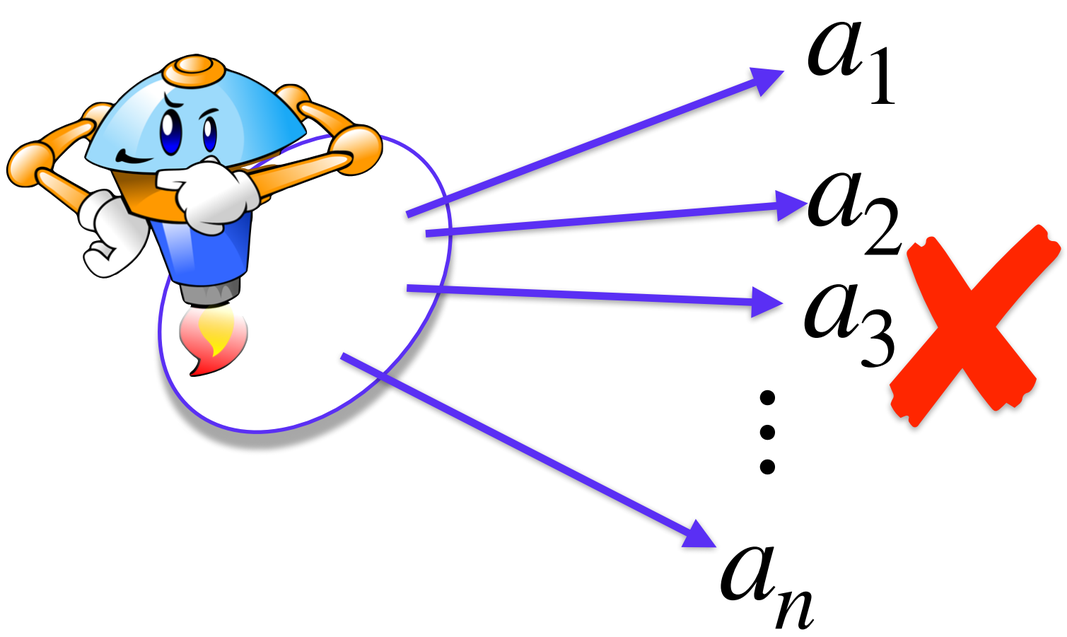
$$V^*(s) = \max_a Q^*(s,a)$$

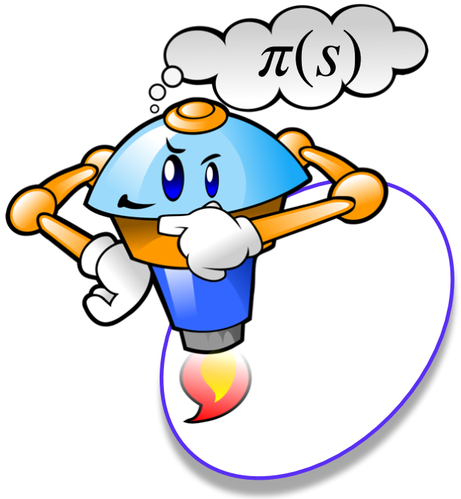
$$Q^*(s,a) = \sum_{s'} T(s,a,s')[R(s,a,s') + \gamma V^*(s')]$$

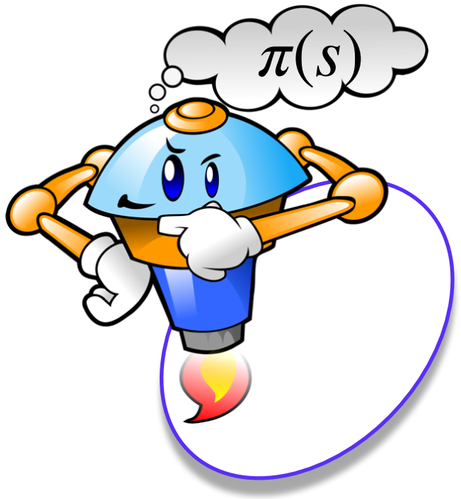





a_1
a_2
a_3
a_n


a_1
a_2
a_3
a_n


$\pi(s)$



… Y si ya tenemos la política definida, ¿cuál es el propósito del agente?



ejecuta la acción para la política

Busca la actualización de la política

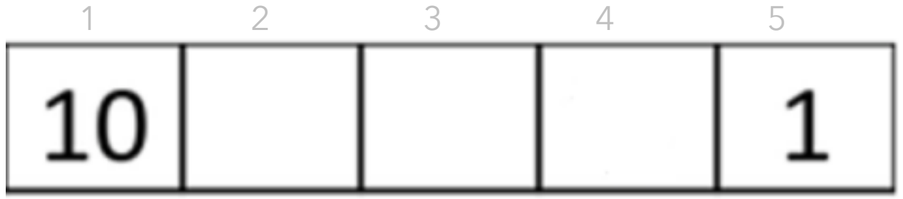


ejecuta la acción para la política

Estabilizar la política

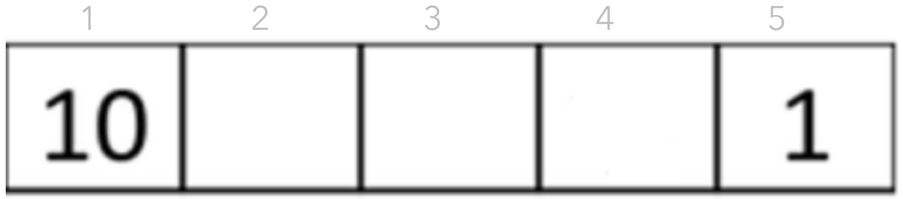
Busca la actualización de la política

Ejercicios

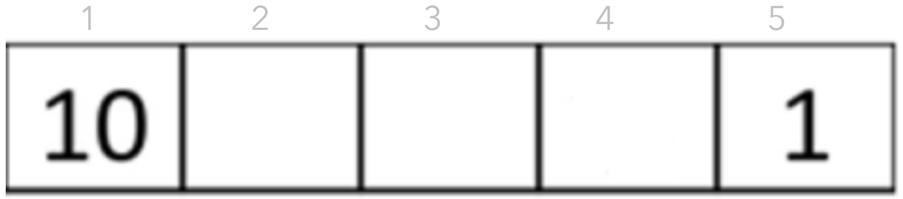


Considere el siguiente escenario de Gridworld (en la figura) con una cuadricula de 1x5 con recompensas de 10 en el extremo izquierdo y 1 en el extremo derecho, respectivamente. Suponga que todas las transiciones son determinísticas, con acciones para ir a la derecha, izquierda o salir (únicamente posible en los extremos).

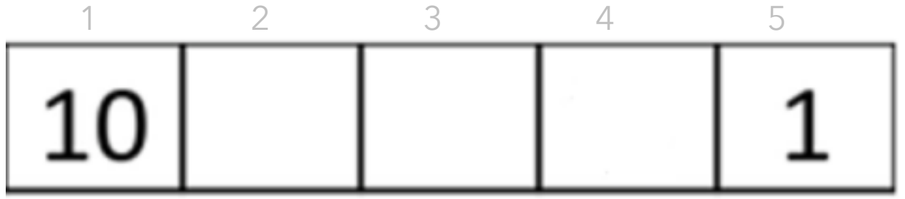
1. ¿Cuál es la política óptima del agente (para todas las casillas) si γ es 1?
2. ¿Cuál es la política óptima del agente (para todas las casillas) si γ es 0.1?
3. ¿Existe algún valor de γ para el cual las acciones derecha o izquierda sean equivalentes para la casilla 4?



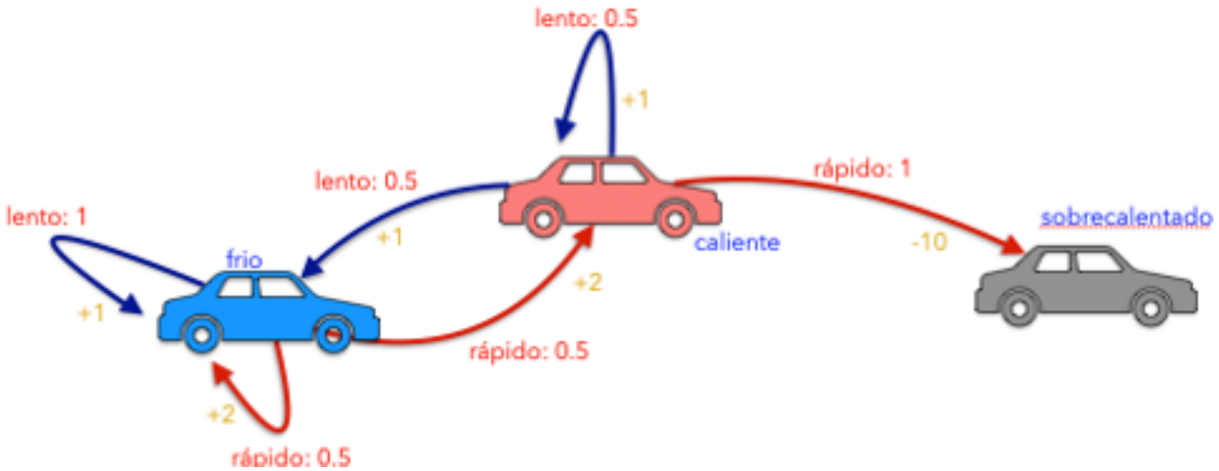
1. ¿Cuál es la política óptima del agente (para todas las casillas) si γ es 1?



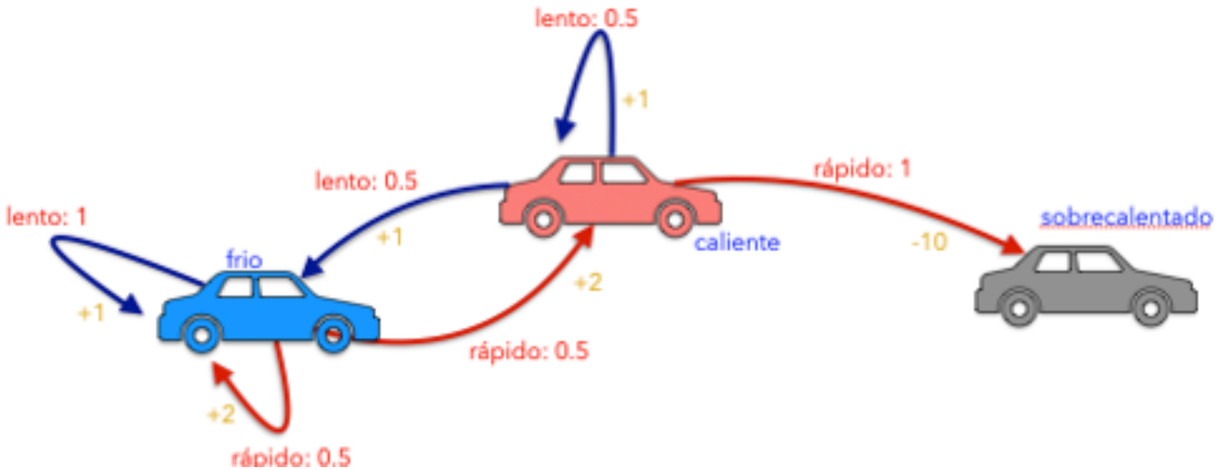
2. ¿Cuál es la política óptima del agente (para todas las casillas) si γ es 0.1?



3. ¿Existe algún valor de γ para el cual las acciones derecha o izquierda sean equivalentes para la casilla 4?



Considere el escenario para los estados de los carros. Evalúe las políticas π: siempre ir rápido y π: siempre ir lento para cada uno de los estados, si el factor de descuento es 0.5.

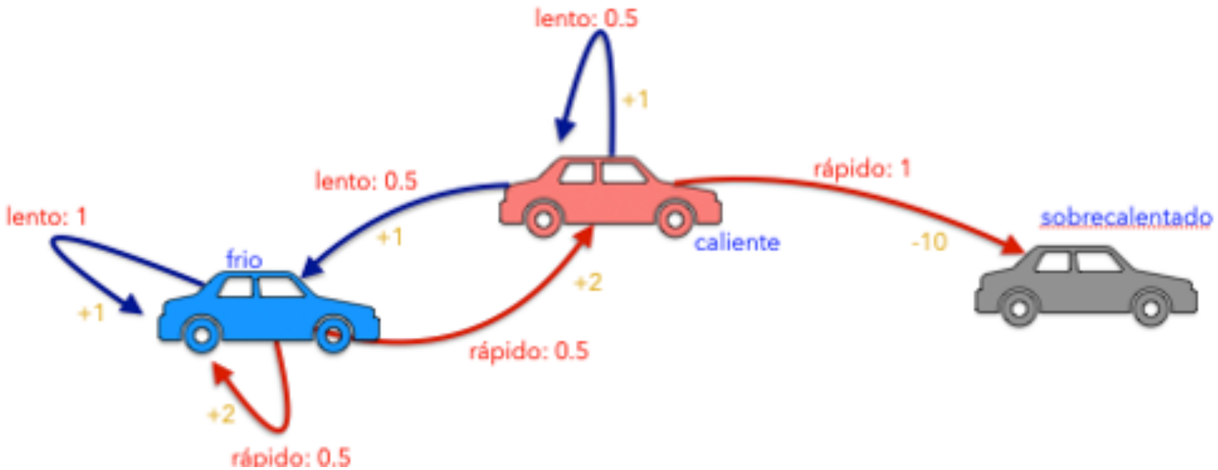


Considere el escenario para los estados de los carros. Evalúe las políticas π: siempre ir rápido y π: siempre ir lento para cada uno de los estados, si el factor de descuento es 0.5.

$$V_R(F) = \frac{1}{2}(2 + \frac{1}{2}V(F)) + \frac{1}{2}(2 + \frac{1}{2}V(C))$$
$$= 2$$

$$V_R(C) = (-10 + \frac{1}{2}V(S))$$
$$= -10$$

$$V_R(S) = 0$$



Considere el escenario para los estados de los carros. Evalúe las políticas π: siempre ir rápido y π: siempre ir lento para cada uno de los estados, si el factor de descuento es 0.5.

$$V_R(F) = \frac{1}{2}(2 + \frac{1}{2}V(F)) + \frac{1}{2}(2 + \frac{1}{2}V(C))$$
$$= 2$$

$$V_R(C) = (-10 + \frac{1}{2}V(S))$$
$$= -10$$

$$V_R(S) = 0$$

$$V_L(F) = (1 + \frac{1}{2}V(F))$$
$$= 1$$

$$V_L(C) = \frac{1}{2}(1 + \frac{1}{2}V(F)) + \frac{1}{2}(1 + \frac{1}{2}V(C))$$
$$= 1$$

$$V_L(S) = 0$$

RECURSO EDUCATIVO DIGITAL

AUTOR(ES)

Profesor Nicolás Cardozo

EQUIPO TÉCNICO

Presentador Nicolás Cardozo

Producción Nicolás Cardozo

Postproducción Nicolás Cardozo

Facultad de Ingeniería
Departamento de Ingeniería de Sistemas y Computación

Vicerrectoría Académica
Conecta-TE, Centro de Innovación en Tecnología y Educación

Universidad de los Andes

Bogotá, Colombia
Febrero 2023

Facultad de Ingeniería

Departamento de Ingeniería de Sistemas y Computación

Aprendizaje por refuerzo

Vicerrectoría Académica

Universidad de los Andes

(Abril/2024)

© - Derechos Reservados: La presente obra, y en general todos sus contenidos, se encuentran protegidos por las normas internacionales y nacionales vigentes sobre propiedad Intelectual, por lo tanto su utilización parcial o total, reproducción, comunicación pública, transformación, distribución, alquiler, préstamo público e importación, total o parcial, en todo o en parte, en formato impreso o digital y en cualquier formato conocido o por conocer, se encuentran prohibidos, y solo serán lícitos en la medida en que se cuente con la autorizaci previa y expresa por escrito de la Universidad de los Andes.

De igual manera, la utilización de la imagen de las personas, docentes o estudiantes, sin su previa autorización está expresamente prohibida. En caso de incumplirse con lo mencionado, se procederá de conformidad con los reglamentos y políticas de la universidad, sin perjuici las demás acciones legales aplicables.